

Projekt 1:

Prawo Zipfa dla języka rumuńskiego

Amelia Adamczuk
Magdalena Bernat

13 stycznia 2025

1 Cel projektu

Projekt ma na celu analizę różnego rodzaju tekstów w języku rumuńskim i utworzenie rankingu najczęściej występujących słów. To z kolei pozwala wyodrębnić zbiory słów, których znajomość umożliwia rozumienie odpowiednio: 10%, 20%, ... 50% wyrazów w czytanych tekstach oraz sprawdzenie zachowania prawa Zipfa dla przedstawionego zbioru tekstów.

2 Analiza tekstów

Do wyodrębnienia najpopularniejszych słów w języku rumuńskim posłużyło nam 13 tekstów, których źródła znajdują się w pliku README w udostępnionym repozytorium. Znajdują się tam między innymi artykuły ze strony Wikipedia, powieści i bajki dla dzieci, a także teksty patriotyczne.

Na potrzeby projektu stworzyliśmy program analizujący dostarczone teksty, z których na początku usuwane są wszystkie znaki specjalne z wyjątkiem pauz (znaków -), które zostają odfiltrowane dopiero po podzieleniu na pojedyncze słowa. Ma to na celu usunięcie łączników z tekstów oraz zachowanie wyrazów pisanych z pauzą, które są często napotymane w języku rumuńskim (tzw. łączniki dysjunkcyjne). Wynikiem programu jest lista słów potrzebnych do zrozumienia odpowiednio: 10%, 20%, 30%, 40% i 50% czytanych tekstów oraz pliki wynik.csv i word_graph.png zawierające ranking wszystkich wyrazów występujących w dostarczonych tekstach oraz graf połączeń między tymi słowami.

3 Wyniki

Po uruchomieniu programu otrzymamy następujące listy słów potrzebne do zrozumienia danego zakresu czytanych tekstów:

1. Słowa konieczne do zrozumienia 10% tekstu:

• de • și • în • să

2. Dodatkowe słowa konieczne do zrozumienia 20% tekstu:

• cu • se • mai • la
• pe • o • a

3. Dodatkové slova konieczne do zrozumienia 30% tekstu:

- | | | | |
|--------|--------|-------|--------|
| • nu | • ce | • lor | • fost |
| • din | • un | • e | • cum |
| • care | • că | • ei | • fi |
| • ca | • când | • dar | |

4. Dodatkové slova konieczne do zrozumienia 40% tekstu:

- | | | | |
|----------|---------|---------|-----------|
| • așa | • fără | • prin | • bine |
| • pentru | • mare | • al | • ochii |
| • lui | • ea | • le | • cele |
| • era | • ori | • cea | • aș |
| • am | • mă | • decât | • lângă |
| • sunt | • unde | • mult | • cât |
| • el | • au | • fie | • apoi |
| • er | • sa | • acum | • spre |
| • i | • până | • sau | • departe |
| • petru | • erau | • cel | • dela |
| • nici | • numai | • odată | • poate |
| • după | • toate | • ale | • încât |
| • tot | • îi | • peste | |

5. Dodatkové slova konieczne do zrozumienia 50% tekstu:

- | | | | |
|----------|-----------|------------|-------------|
| • trei | • cei | • acolo | • chiar |
| • este | • ele | • zorilor | • foarte |
| • aceste | • ceva | • lume | • cine |
| • zise | • va | • făcut | • căci |
| • mine | • pământ | • ci | • lumea |
| • loc | • florița | • văzut | • vreme |
| • asupra | • cari | • supt | • vor |
| • dacă | • către | • bună | • omul |
| • eu | • flori | • parte | • stavrache |
| • își | • te | • mari | • vorbă |
| • îl | • nimic | • atâta | • acum |
| • una | • urmă | • îmi | • întrun |
| • încă | • însă | • unul | • jos |
| • între | • ai | • aceea | • adesea |
| • ar | • na | • frumoasă | • popa |
| • întro | • aici | • aproape | • toată |
| • mea | • iar | • n | • facă |
| • multe | • face | • zi | • om |
| | | | • niște |
| | | | • vād |

- | | | | |
|-----------|-------------|------------|-------------|
| • știe | • locul | • aceia | • vede |
| • mână | • li | • dintre | • da |
| • acest | • dumnezeu | • apă | • față |
| • despre | • mâna | • făc | • totdeauna |
| • cale | • sus | • atâtea | • jumătate |
| • zile | • ani | • trebuie | • sufletul |
| • țară | • mijlocul | • soarelui | • părea |
| • asta | • aceasta | • inima | • murgul |
| • să-i | • două | • are | • so |
| • lucru | • niciodată | • înainte | • jurul |
| • casă | • această | • alta | • capul |
| • încep | • mele | • fusese | • pot |
| • prea | • atunci | • orice | • pline |
| • fața | • noi | • unui | |
| • fiecare | • puțin | • sub | |

4 Prawo Zipfa

Prawo Zipfa głosi, że wiele rodzajów danych tworzonych przez ludzi cechuje charakterystyczny rozkład wartości, w którym dystrybucja częstotliwości występowania poszczególnych wartości jest odwrotnie proporcjonalna do ich rangi statystycznej. Można to zapisać w postaci równania:

$$r * f = \text{constans} \quad (1)$$

gdzie r to ranga wyrazu w tekście lub grupie tekstów, a f to częstotliwość jego występowania. W przedstawionym poniżej rankingu słów znajdują się współczynniki obliczone na podstawie podanego wyżej równania. Na ich podstawie można zaobserwować, że prawo Zipfa w kontekście języka rumuńskiego może nie działać w sposób tak wyraźny, jak w innych językach, ale nadal stanowi cenny punkt wyjścia do ogólnego zrozumienia użycia słów i języka.

5 Ranking

Podane powyżej listy zawierają 209 słów potrzebnych do zrozumienia 50% tekstu czytanego w języku rumuńskim. Poniżej umieszczone zostały tabele przedstawiające najpopularniejsze słowa pojawiające się w wykorzystanych przez nas tekstach wraz z ich liczbą wystąpień, numerem w rankingu oraz współczynnikiem będącym iloczynem tych dwóch wartości. Z racji, że liczba wszystkich różnych słów znajdujących się w wybranych przez nas tekstach przekracza 14000, w poniższych tabelach uwzględnione zostało pierwsze 300 wyróżnionych wyrazów.

Słowo	Wartość	Ranga	Współczynnik
de	3846	1	3846
și	2919	2	5838
în	1941	3	5823
să	1387	4	5548
cu	1351	5	6755
pe	1302	6	7812
se	1257	7	8799
o	1131	8	9048
mai	1121	9	10089
a	1027	10	10270
la	1013	11	11143
nu	899	12	10788
din	867	13	11271
care	793	14	11102
ca	734	15	11010
ce	689	16	11024
un	666	17	11322
că	499	18	8982
când	452	19	8588
lor	397	20	7940
e	385	21	8085
ei	350	22	7700
dar	344	23	7912
fost	342	24	8208
cum	325	25	8125
fi	296	26	7696
așa	269	27	7263
pentru	256	28	7168
lui	255	29	7395
era	253	30	7590
am	252	31	7812
sunt	242	32	7744
el	235	33	7755
er	234	34	7956
i	232	35	8120
petru	228	36	8208
nici	226	37	8362
după	223	38	8474
tot	218	39	8502
fără	212	40	8480
mare	201	41	8241
ea	197	42	8274
ori	194	43	8342
mă	188	44	8272
unde	187	45	8415
au	184	46	8464
sa	175	47	8225
până	175	48	8400
erau	170	49	8330
numai	170	50	8500

Słowo	Wartość	Ranga	Współczynnik
toate	161	51	8211
îi	161	52	8372
prin	160	53	8480
al	160	54	8640
le	150	55	8250
cea	145	56	8120
decât	142	57	8094
mult	141	58	8178
fie	138	59	8142
acuma	135	60	8100
sau	131	61	7991
cel	130	62	8060
odată	127	63	8001
ale	122	64	7808
peste	122	65	7930
bine	122	66	8052
ochii	119	67	7973
cele	117	68	7956
aș	116	69	8004
lângă	114	70	7980
cât	113	71	8023
apoi	112	72	8064
spre	111	73	8103
departe	111	74	8214
dela	111	75	8325
poate	111	76	8436
încât	109	77	8393
trei	108	78	8424
este	106	79	8374
aceste	104	80	8320
zise	102	81	8262
mine	102	82	8364
loc	102	83	8466
asupra	101	84	8484
dacă	101	85	8585
eu	99	86	8514
își	97	87	8439
îl	92	88	8096
una	92	89	8188
încă	91	90	8190
între	91	91	8281
ar	90	92	8280
întro	90	93	8370
mea	90	94	8460
multe	90	95	8550
cei	88	96	8448
ele	88	97	8536
ceva	87	98	8526
va	84	99	8316
pământ	84	100	8400

Słowo	Wartość	Ranga	Współczynnik
florița	84	101	8484
cari	82	102	8364
către	79	103	8137
flori	78	104	8112
te	77	105	8085
nimic	76	106	8056
urmă	74	107	7918
însă	74	108	7992
ai	74	109	8066
na	74	110	8140
aici	74	111	8214
iar	73	112	8176
face	73	113	8249
acolo	73	114	8322
zorilor	73	115	8395
lume	73	116	8468
făcut	73	117	8541
ci	72	118	8496
văzut	72	119	8568
supt	72	120	8640
bună	70	121	8470
parte	69	122	8418
mari	69	123	8487
atâta	69	124	8556
îmi	69	125	8625
unul	68	126	8568
aceea	68	127	8636
frumoasă	68	128	8704
aproape	68	129	8772
n	68	130	8840
zi	67	131	8777
chiar	65	132	8580
foarte	65	133	8645
cine	65	134	8710
căci	64	135	8640
lumea	64	136	8704
vreme	64	137	8768
vor	63	138	8694
omul	63	139	8757
stavrache	63	140	8820
vorbă	62	141	8742
acum	61	142	8662
întrun	61	143	8723
jos	60	144	8640
adesea	60	145	8700
popa	60	146	8760
toată	59	147	8673
facă	59	148	8732
om	58	149	8642
niște	58	150	8700

Słowo	Wartość	Ranga	Współczynnik
văd	58	151	8758
știe	57	152	8664
mână	56	153	8568
acest	56	154	8624
despre	56	155	8680
cale	56	156	8736
zile	56	157	8792
țară	56	158	8848
asta	56	159	8904
să-i	56	160	8960
lucru	55	161	8855
casă	55	162	8910
încep	55	163	8965
prea	55	164	9020
fața	55	165	9075
fiecare	55	166	9130
locul	55	167	9185
li	55	168	9240
dumnezeu	54	169	9126
mâna	54	170	9180
sus	54	171	9234
ani	53	172	9116
mijlocul	53	173	9169
aceasta	53	174	9222
două	53	175	9275
niciodată	53	176	9328
această	53	177	9381
mele	53	178	9434
atunci	52	179	9308
noi	52	180	9360
puțin	52	181	9412
aceia	52	182	9464
dintre	51	183	9333
apă	51	184	9384
fac	51	185	9435
atâtea	51	186	9486
trebuie	51	187	9537
soarelui	50	188	9400
inima	50	189	9450
are	50	190	9500
înainte	49	191	9359
alta	49	192	9408
fusese	49	193	9457
orice	49	194	9506
unui	48	195	9360
sub	48	196	9408
vede	48	197	9456
da	48	198	9504
față	48	199	9552
totdeauna	48	200	9600

Słowo	Wartość	Ranga	Współczynnik
jumătate	47	201	9447
sufletul	47	202	9494
părea	47	203	9541
murgul	47	204	9588
so	47	205	9635
jurul	47	206	9682
capul	46	207	9522
pot	46	208	9568
pline	46	209	9614
fel	46	210	9660
ne	45	211	9495
atât	45	212	9540
văz	45	213	9585
putut	45	214	9630
mam	45	215	9675
alte	44	216	9504
putea	44	217	9548
dat	44	218	9592
doi	44	219	9636
să-l	44	220	9680
aur	44	221	9724
sânta	44	222	9768
nouă	44	223	9812
casa	44	224	9856
soarele	43	225	9675
frumos	43	226	9718
de-a	43	227	9761
câte	43	228	9804
ochi	42	229	9618
lumina	42	230	9660
înnainte	42	231	9702
locuri	42	232	9744
noapte	41	233	9553
nimeni	41	234	9594
acela	41	235	9635
altul	41	236	9676
afară	41	237	9717
frumoase	41	238	9758
lucruri	41	239	9799
zilele	41	240	9840
mieu	41	241	9881
precum	40	242	9680
împăratul	40	243	9720
intră	40	244	9760
bun	40	245	9800
drum	40	246	9840
lumină	40	247	9880
multă	40	248	9920
știu	40	249	9960
picioare	40	250	10000

Słowo	Wartość	Ranga	Współczynnik
toți	40	251	10040
fiind	39	252	9828
nam	39	253	9867
drept	38	254	9652
greu	38	255	9690
împărat	38	256	9728
luă	38	257	9766
țara	38	258	9804
pute	38	259	9842
tu	38	260	9880
iarăși	38	261	9918
i-a	38	262	9956
mânile	38	263	9994
astfel	37	264	9768
vechi	37	265	9805
pământul	37	266	9842
nou	37	267	9879
lung	37	268	9916
mici	37	269	9953
bucurie	37	270	9990
mi-a	37	271	10027
acestea	36	272	9792
vinere	36	273	9828
d-l	36	274	9864
cal	35	275	9625
vis	35	276	9660
să-și	35	277	9695
vin	35	278	9730
noastre	35	279	9765
biserică	34	280	9520
merse	34	281	9554
tare	34	282	9588
cap	34	283	9622
voi	34	284	9656
trecut	34	285	9690
răspunse	34	286	9724
vine	34	287	9758
hoții	34	288	9792
câteva	33	289	9537
acesta	33	290	9570
ziua	33	291	9603
drumul	33	292	9636
ac	33	293	9669
sar	33	294	9702
vorba	33	295	9735
său	33	296	9768
stă	33	297	9801
florile	33	298	9834
ridică	33	299	9867
frumuseță	33	300	9900

6 Graf połączeń językowych

